

СИСТЕМА ПРОГНОЗИРОВАНИЯ ОЖИДАЕМЫХ ГОДОВЫХ МЕДИЦИНСКИХ РАСХОДОВ ПАЦИЕНТА ДЛЯ СТРАХОВОГО АНАЛИТИКА

Команда №6



Наша команда:

- Дмитрий - **Team Lead** - руководит проектом, определяет архитектуру, наводит на нужный путь и делает ревью.
- Валентина - **Data Scientist** - проводит аналитику данных, готовит датасет для ML, строит модели ML.
- Артур - **Backend** - разрабатывает бэкенд, отвечающий за ML-инференс, бизнес-логику и работу с БД.
- Илья - **Frontend** - разрабатывает интерфейс прототипа: формы ввода, отображение результатов и навигацию по приложению.
- Алёна - **QA** - проводит тестирование прототипа, оценивает качество системы.
- Матвей - **PM/BA** - отвечает за бизнес-метрики, представляет проект на отчётных занятиях.

Ссылки на участников:

- Дмитрий - <https://github.com/horacemtb>
- Валентина - <https://github.com/Valuxalo>
- Артур - <https://github.com/Archistein>
- Ильясия - <https://github.com/sultanovailsiya-rgb>
- Алёна - <https://github.com/al-lozinskaya>
- Матвей - <https://github.com/qwemiracle1337>

Итоги 3 спринта и проекта:

- Расчет метрик и оформление документации
- Формирование дашборда
- Подключение DaData
- Тестирование прототипа и исправление багов
- Анализ выполненных задач



Расчет метрик:

- Метрики ML
- Метрики операционной эффективности
- Архитектурные метрики надежности
- Метрики Tesseract OCR



Метрики ML:

В КА

- MAE - 37,09 (95 % CI [28,64; 49,94])
- RMSE - 176,75
- R^2 - 0,9993
- MAPE - 0,0018



Метрики ML:

Модель	MAE	RMSE	R ²	MAPE
CatBoost	35.26 [29.85; 44.13]	117.64 [42.76; 215.90]	0.9997 [0.9991; 1.0000]	0.0018 [0.0017; 0.0020]
CatBoost SHAP-selected	37.09 [28.64; 49.94]	176.75 [48.73; 330.49]	0.9993 [0.9979; 1.0000]	0.0018 [0.0016; 0.0021]
HistGradientBoosting	286.16 [256.78; 324.12]	591.25 [381.34; 863.46]	0.9929 [0.9860; 0.9970]	0.0151 [0.0141; 0.0162]
Random Forest	991.31 [938.70; 1050.68]	1334.38 [1246.41; 1437.86]	0.9654 [0.9606; 0.9695]	0.0569 [0.0537; 0.0604]
Best Linear ElasticNet	1083.21 [1011.97; 1158.43]	1598.57 [1421.91; 1797.68]	0.9503 [0.9406; 0.9584]	0.0550 [0.0524; 0.0576]

Главный результат ML исследования:

- Лучшими по качеству на test оказались две модели: CatBoostRegressor и CatBoostRegressor_SHAP_selected.
- По результатам paired bootstrap-сравнения по метрике MAE статистически значимой разницы между ними не обнаружено: 95% доверительный интервал для разницы MAE включает 0.
- На имеющейся тестовой выборке нельзя утверждать, что полная CatBoost-модель лучше сокращённой версии на основе SHAP-отбора признаков.
- С учётом сопоставимого качества и меньшего числа признаков в качестве финальной модели можно выбрать CatBoostRegressor_SHAP_selected как более компактную и интерпретируемую.



Метрики операционной эффективности:

- Time Reduction %
- Cost Saved per Month
- OPEX
- Cost per Inference
- Return on Investment (ROI)

Time Reduction %:

$\text{Time Reduction \%} = (\text{Базовое время} - \text{Новое время}) / \text{Базовое время} \times 100\%$

Базовые расходы (в среднем) = 60 мин

Новые расходы (в среднем) = 10 мин

Time Reduction % = 83% снижения затрат по времени

Cost Saved per Month:

Рассчитаем для средней компании и средней зарплате аналитика 100 000 руб/мес.

Cost Saved per Month = (Базовое время - Новое время) × Часовая ставка аналитика ×
Количество прогнозов

Cost Saved per Month = (50 мин/60)час × 650 руб/час × 18000 прогнозов/мес = 9 750 000
руб/мес

OPEX (Operating Expenses):

Стоимость аренды двух серверов в облаке с данными параметрами (Yandex Cloud) - 55 000 руб/мес.

Стоимость аренды PostgreSQL в облаке (Yandex Cloud) - 40 000 руб/мес.

Интеграция с dadata: подсказки 10000 запросов в день - бесплатно;
стандартизация - 7200 руб/мес.

Техническая поддержка (обновление, восстановление после сбоев, поддержка) - 50 000 руб/мес.

OPEX = 152 200 руб/мес.

Cost per Inference:

$\text{Cost per Inference} = (\text{Затраты на инфраструктуру модели за период}) /$
 $(\text{Количество инференсов за период})$

Затраты на инфраструктуру модели за период = 147 200 руб/мес.

Количество инференсов за период = 36 000 в мес

Cost per Inference = 4.1 руб.

Return on Investment (ROI):

$$\underline{ROI \text{ (месячный)}} = (\text{Cost Saved} - \text{OPEX}) / \text{OPEX} \times 100\%$$

$$\underline{ROI \text{ (месячный)}} = 6306 \%$$

Архитектурные метрики надежности:

- Latency
- Throughput
- API Error Rate
- Initial Load Time



Latency:

Время ответа системы на запрос расчёта предсказания прогноза:

Latency P95 = 57,237 мсек. (10000 запросов на локальный сервер)

Для удалённого сервера **Latency P95** $\approx$ 200 мсек.

Throughput:

Показатель того, сколько операций система обрабатывает в единицу времени:

Throughput = 14 прогнозов/сек.

API Error Rate (частота ошибок API):

Отношение числа неспешных запросов к числу успешных:

$$\textbf{\underline{API Error Rate}} = 0,03 \%$$

Initial Load Time (время начальной загрузки):

Initial Load Time P95 = 2,23 сек.

Метрики Tesseract OCR:

- Среднее время распознавания анкеты
- Accuracy
- CER (Character Error Rate)



Среднее время распознавания анкеты OCR:

Time OCR = 3,51 сек

Accuracy:

Точность для печатных документов (идеальные условия). Процент правильно распознанных символов или слов от их общего количества в эталонном тексте.

Accuracy = 95% - 98%

CER (Character Error Rate):

Частота ошибок на уровне отдельных символов. Считает количество вставленных, удаленных или замененных символов.

CER = 1.5% - 2.5% - для фото документов


Ссылка на документацию:

<https://github.com/horacemtb/medcost-prediction-app/blob/main/README.md>



Формирование дашборда:

- Сводный обзор
- Профиль рисков
- Отклонение прогноза от исторической выборки
- Распределение по полу
- Монитор объяснимости



Подключение Dadata:

- Выпадающий список адресов
- Исправление введенных данных

Адрес

- г Санкт-Петербург
- Самарская обл
- Саратовская обл
- респ Саха (Якутия)
- г Самара

Тестирование прототипа:

По итогам функционального тестирования все восемь пользовательских сценариев успешно проходят основные потоки. Зафиксированный Task Success Rate составил 100 %. Альтернативные потоки также обрабатывают корректно:

- некорректные данные приводят к ожидаемым HTTP 400
- отсутствие записи в БД — к HTTP 404 без падения интерфейса
- ошибки OCR — к подробному списку warnings
- ошибка PDF-генерации возвращает понятное пользователю сообщение.



Поставленные в начале проекта задачи выполнены:

- Проведён анализ рынка ДМС и сформировано экономическое обоснование
- Определена целевая аудитория продукта
- Выполнен бенчмаркинг конкурентов и зафиксирована свободная ниша
- Спроектированы архитектура системы, REST API из двенадцати эндпойнтов и логическая модель данных
- Проведено самостоятельное ML-исследование с сравнением десяти классов моделей
- Реализован прототип, включающий веб-интерфейс на React, бэкенд на FastAPI, базу данных PostgreSQL, OCR-подсистему на Tesseract и интеграцию с Dadata
- Проведено функциональное и нефункциональное тестирование, рассчитаны операционные, архитектурные и ML-метрики

Направления дальнейшего развития:

- переход от синтетического датасета к реальным данным страховой компании с пересборкой ML-модели и внедрением мониторинга дрейфа данных через PS
- реализация системы авторизации и ролевой модели (JWT-токены, разграничение ролей «аналитик» и «руководитель»)
- расширение feature set ML-модели за счёт перехода на расширенный датасет (100 000 наблюдений, 50+ признаков)
- интеграция продукта с корпоративными CRM, BI-системами и каналами поступления заявок страховых компаний
- развитие OCR-подсистемы для работы с произвольными форматами анкет (не только типовая форма)